22.05.2019

AIRBNB-WOHNUNGEN & SEHENSWÜRDIGKEITEN IN BERLIN

Fragestellung: Besteht ein Zusammenhang zwischen der Dichte an Sehenswürdigkeiten und der Anzahl sowie dem Preis von Airbnb-Wohnungen in den unterschiedlichen Berliner Bezirken?

Projekt im Modul „Semantic Web“ im Sommersemester 2019
Hannah Beck, 2. Sem. Medieninformatik Master, Fakultät Informatik & Medien

DATENQUELLEN

	Inside Airbnb – Adding data to the debate	Berlin.de	Wikipedia
LINK	http://insideairbnb.com	https://www.berlin.de	https://de.wikipedia.org
DATEN	Airbnb-Unterkünfte	Sehenswürdigkeiten	Berliner Bezirke
QUALITÄT	CSV ★ ★ ★	HTML ★ ★	HTML ★ ★

DATENGEWINNUNG



1. Daten aus den HTML-Seiten extrahieren durch Python-basierten Webcrawler mithilfe des Frameworks Scrapy.
2. Daten im CSV-Format speichern.

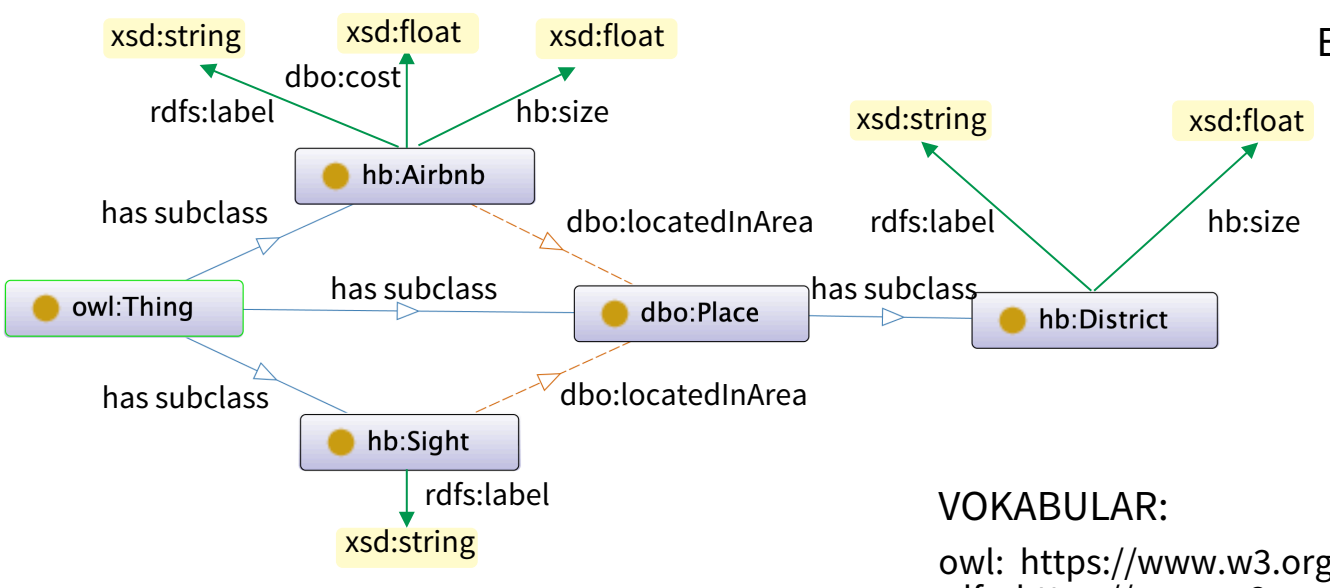
```python
class QuotesSpider(scrapy.Spider):
    name = "sights"
    start_urls = [
        'https://www.berlin.de/sehenswuerdigkeiten/bezirk/mitte/',
        'https://www.berlin.de/sehenswuerdigkeiten/bezirk/pankow/',
    ]

    def parse(self, response):
        for sight in response.xpath('body'):
            yield {
                'SightsPankow': sight.xpath('//main/div[.//*[contains(text(),
                "Pankow")]]/article[@class="block teaser"]/h3/a/text()').getall(),

                'SightsMitte': sight.xpath('//main/div[.//*[contains(text(),
                "Mitte")]]/article[@class="block teaser"]/h3/a/text()').getall(),
            }
```

Codebeispiel:
Extraktion der Sehenswürdigkeiten in Mitte & Pankow

ONTOLOGIE



ERSTELLT MIT: Protégé

Class
Data Property
Object Property
Class Hierarchy

VOKABULAR:

owl: https://www.w3.org/2002/07/owl#
rdfs: https://www.w3.org/2000/01/rdf-schema#
dbo: http://dbpedia.org/ontology/
xsd: https://www.w3.org/2001/XMLSchema#
hb: https://gitlab.imn.htwk-leipzig.de/hbeck/ont#

I-HTWK
Hochschule für Technik, Wirtschaft und Kultur Leipzig