Welche Musiker der amerikanischen Top 100 Charts erwähnen die meisten Firmennamen in ihren Songtexten?

22. Mai 2019 - Projekt von Jonas Eichler (Medieninformatik Master) für das Modul “Semantic Web” unter der Leitung von Prof. Dr. Thomas Riechert

Datenquellen:

billboard

Daten:
Songtitel und Namen von Künstlern der Top 100 Billboard Charts (Zeitspanne definierbar)

Zugriff via:
Billboard API
https://github.com/guoguo12/billboard-charts

Dateiformat:
ChartData Objekt

GENIUS

Daten:
Songtexte der gefundenen Titel

Zugriff via:
Genius API
https://github.com/johnwmillr/LyricsGenius

Dateiformat:
Song Objekt (Songtext als String)

DBpedia Spotlight

Daten:
Wahrheitswert ob gefundenes Wort der Name einer Firma ist (durch untersuchen der ‘types’ Eigenschaft)

Zugriff via:
Spotlight API
https://github.com/ubergrape/pyspotlight

Dateiformat:
Boolean Wert

Workflow:

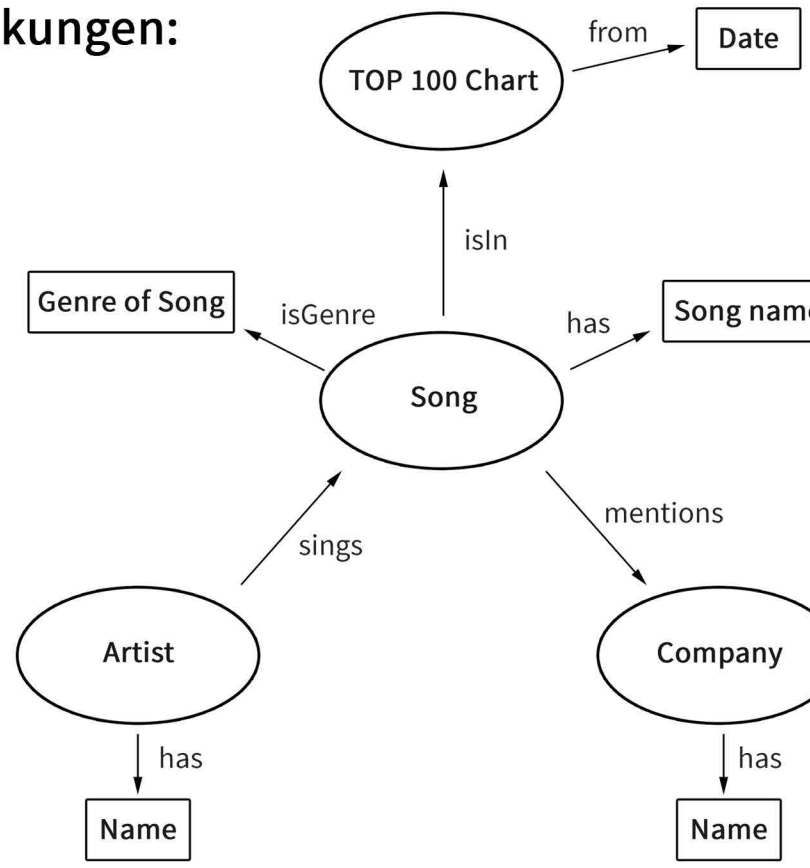
1. **Definieren des Zeitraums der Stichproben**
   - Analysieren der Top 100 Charts für einen Tag pro Monat über mehrere Jahre hinweg

2. **Iterieren durch Songtexte**
   - Worterkennung mit NLTK (Natural Language Toolkit)
   - Filtern der Songtexte:
     - Nur Wörter mit Großbuchstaben
     - Abgleich mit ‘stopword’ Liste
     - Wörter werden nicht doppelt kontrolliert

3. **Kontrollieren** ob gefundene Strings Namen von Firmen sind (mit DBpedia Spotlight)

4. **Abspeichern** in Datenstruktur

Verlinkungen:



Namespace: https://gitlab.imn.htwk-leipzig.de/jeichle/ont